


Rethinking Intelligence: Brain-like Neuron Network

2026年4月13日

発表者：小林勇太



- ① 論文概要
- ② 導入
- ③ BNN
- ④ LuminaNet
- ⑤ 実験
- ⑥ まとめ



LuminaNet


脳の構造と進化的ダイナミクスを模倣した、 新たなニューラルネットワークのパラダイムを提案

課題

主流なNNは生物学的
神経系と根本的に異なる

生物の脳


✓ 動的で不均一



※イメージ図

主流なNN

✓ 静的で均一



※イメージ図

解決

生物学的神経系と進化経路を
模倣する手法を提案



構造定義

帰納バイアス

畳み込み
カーネル

アテンション
機構

進化ルールのみを定義

結果

自己進化によって形成された
複雑なトポロジカル構造が性能を向上させる



生物の脳

- 複雑かつ効率的な情報処理システム
- 資源等の制約の中でも多層的な認知機能を実現可能
 - ✓ 知覚、学習、推論、創造性など



脳を模倣したシステムを実現・活用できれば、
革命が起きる

脳に着想を得た人工知能システム

- Deep Learning
- 大規模言語モデル

生物学的神経とは
根本的に異なる



生物の脳と主流なニューラルネットワークの違い

生物の脳

主流なNN



構造構築

動的

静的



帰納バイアス

なし

あり

生物の脳

本研究

発達過程の神経回路の複雑な構造を、**ゼロから生物学的な脳の構造と進化的ダイナミクス**の観点から知能の起源と進化を再考する
パラダイム提案

主流なNN

データの持つ関係性を人間が
手動で設計し、それを学習する
**（CNNの例: 隣接するピクセルに
関係性があるという前提）**



BNNは特定のアーキテクチャではなく、
以下のように形式的に定義できる新しいパラダイム

非人工的な構造

- 自己組織化によって構造が決定

脳と同様の構造的仮説


- 生物学的神経系と整合する構造上の制約と計算原理

自律的な進化能力

- 構造の調整、幅と深さの自己組織化、接続の自発的な形成
- 進化プロセスを通じた性能の維持と向上

高い解釈可能性

- 構造の進化、データの流れ、情報の伝播の点において高い解釈可能性を示す



1

入力層 (IL)

- 元の入力を潜在空間に埋め込む

2

ニューロン層 (NL)

- 特徴量を抽出し統合する
- NLのニューロンは成長可能

3

通信層 (CL)

- NLに織り込まれた単一の層
- ニューロンクラスター間のシナプス通信を再現
(順伝播、逆伝播、再帰的な接続)

4

出力層 (OL)

- すべてのニューロンクラスターからの出力を統合
- 最終結果を生成




LuminaNet: パラダイムに準拠したモデル




生物の脳

- 生物学的な脳^{の構造}と進化的ダイナミクスを反映
- 一次視覚野への網膜視蓋路を参考に構築



既存手法に依存しない

- 畳み込みカーネルやアテンション機構を用いない
- 進化ルールのみを定義



4つの基本操作

- 分裂・成長・接続・剪定
- 自律的にトポロジカル構造を変化させ自己進化を実現



学習方法について

- ・テスト用のコードは公開されているが、学習用のコードは未公開
- ・論文内にもアルゴリズムの記載があまりない
- ・図と式の変数や添え字の解釈が合わない

以降、正確なアルゴリズムの紹介ではないため注意

✧ Testing

```
python test_<cifar10/tinystories>.py
```



✧ Training

Training code will be released soon.




図2. ニューロンクラスターの構造

特徴

- クラスターを最小単位のモジュールとして定義
- クラスター同士で通信を行う
- クラスター数や接続、クラスター内の構造が自律的に変化する




図2. ニューロンクラスターの構造

入力層(IL)

- 元の入力を潜在空間に埋め込む

ニューロン層(NL)

- 特徴量を抽出し統合する

通信層(CL)

- ニューロンクラスター間のシナプス通信を再現

出力層(OL)

- 最終結果を生成




図2. ニューロンクラスターの構造

入力層(IL)

1. 入力データをパッチに分割
(クラスター数分)
2. 1次元化した後、Embeddingを行う
3. 活性化関数に通す

$$e_i = \sigma \left(\text{Linear}_i(\text{Flatten}(x_i)) \right) \quad (1)$$




図2. ニューロンクラスターの構造

ニューロン層(NL)

1. 入力層と通信層の値を入力とする
2. 線形変換（中間次元 $\Rightarrow$ ニューロン数）
3. 活性化関数（SiLU）
4. ドロップアウト
5. 線形変換（中間次元 $\Rightarrow$ ニューロン数）
6. 活性化関数（SiLU）

$$f_j = NL_j \left(\frac{e_j + \sum_{i \in N_j^f} W_{C_i} f_i}{1 + |N_j^f|} \right) \quad (4)$$

$$f_j^{re} = NL_j \left(\frac{\sum_{i \in \tilde{N}_j^f} W_{C_i} f_i^{re} + \sum_{k \in N_j^b} W_{C_k} f_k}{|\tilde{N}_j^f| + |N_j^b|} \right) \quad (6)$$

後述




図2. ニューロンクラスターの構造

通信層(CL)

1. 接続する他クラスターの出力に、重みを掛ける
2. 全ての接続に関して計算した後、データをNLに渡す

$$f_j = NL_j \left(\frac{e_j + \sum_{i \in N_j^f} W_{C_i} f_i}{1 + |N_j^f|} \right) \quad (4)$$

$$f_j^{re} = NL_j \left(\frac{\sum_{i \in \tilde{N}_j^f} W_{C_i} f_i^{re} + \sum_{k \in N_j^b} W_{C_k} f_k}{|\tilde{N}_j^f| + |N_j^b|} \right) \quad (6)$$




図2. ニューロンクラスターの構造

出力層(OL)

1. 全クラスターの最終的な出力から、予測値を生成する

$$O_j = \{f_j\} \cup \{f_j^{re} | f_j^{re} \text{ exists}\} \quad (7)$$

$$\bar{o} = \frac{\sum_{j=1}^n \sum_{o \in O_j} o}{\sum_{j=1}^n |O_j|} \quad (8)$$





図2. ニューロンクラスターの構造 (Two-Pass Forward method)

$$f_j = NL_j \left(\frac{e_j + \sum_{i \in N_j^f} W_{C_i} f_i}{1 + |N_j^f|} \right) \quad (4)$$

$$f_j^{re} = NL_j \left(\frac{\sum_{i \in \tilde{N}_j^f} W_{C_i} f_i^{re} + \sum_{k \in N_j^b} W_{C_k} f_k}{|\tilde{N}_j^f| + |N_j^b|} \right) \quad (6)$$



進化戦略

Split Strategy

- 分散が α 分位点を超えるクラスターを選択
- 処理能力の分布を均等にするためにクラスターを分割する

Connect Strategy

- 分散の大きいクラスターと小さいクラスターを接続
- indexが $i < j$ である2つのクラスター
 $u_i > u_j$: 順方向接続 $i \rightarrow j$
else : 逆方向接続 $j \rightarrow i$

Grow Strategy

- 分散が β 分位点を超えるクラスターを選択
- ニューロン層のニューロン数を増やして処理能力を工場

Prune Strategy

- 閾値 θ を超える接続を選定する

$$th_j = \theta \cdot \frac{\sum_{i \in N_j^f \cup N_j^b} \|W_{Ci}\|_F}{|N_j^f \cup N_j^b|} \quad (9)$$



実験①：画像認識

- ベースライン比較
- LuminaNetの詳細
- アブレーション
- 入力層・ニューロン層の可視化
- 接続解析
- 構造の可視化

実験②：テキスト生成

- ベースライン比較
- アブレーション（省略）
- 構造の可視化（省略）



Table 1: Baseline comparison for the image recognition task, sorted by Top-1 accuracy rate

Model	Params (M)	Structure	Evolve (Params)	Top-1	Top-3	Top-5	Rank-1	Rank-3	Rank-5
gMLP-15 [41]	1.60	MLP	-	57.38	83.72	92.71	18	18	18
LeNet-5 [5]	0.06	CNN	-	62.81	86.87	94.69	17	17	17
MobileNet-V3 [38]*	1.67	CNN	-	63.16	89.63	96.72	16	15	11
MLP-Mixer [7]	3.80	MLP	-	64.99	89.92	96.56	15	14	12
DeiT-Tiny [9]	5.68	ViT	-	66.81	89.20	95.93	14	16	14
AlexNet [6]	2.47	CNN	-	68.54	90.24	96.28	13	13	13
LuminaNet-10	0.36	BNN	0.03 → 0.36	69.28	91.87	97.58	12	11	8
ResMLP-6 [8]	3.36	MLP	-	71.53	92.19	97.28	11	10	10
LuminaNet-128	3.16	BNN	0.79 → 3.16	72.84	92.59	97.84	10	9	6
LuminaNet-32	1.43	BNN	0.12 → 1.43	73.12	92.98	97.83	9	6	7
LuminaNet-64	2.14	BNN	0.30 → 2.14	73.58	93.29	97.86	8	5	5
LuminaNet-84	1.86	BNN	0.43 → 1.86	74.00	93.74	98.09	7	4	4
MobileViT [19]	5.33	ViT	-	75.62	92.95	97.39	6	7	9
PreAct-ResNet-20 [40]	0.27	CNN	-	76.27	91.22	95.40	5	12	15
MobileNet-V2 [37]*	2.24	CNN	-	79.27	95.10	98.17	4	3	3
PreAct-ResNet-110 [40]	1.73	CNN	-	82.53	92.82	95.23	3	8	16
ResNet18 [20]	11.69	CNN	-	87.96	97.59	99.41	2	2	2
DenseNet-100BC [39]	0.77	CNN	-	90.06	98.32	99.61	1	1	1

BNNパラダイムが静的な深層学習に匹敵するポテンシャルを有する



Table 3: The detailed evolution trajectories of several LuminaNets mentioned in Table 1

Dim.	Params (M)	Clusters	Connections	Topological Depth	Max In-Degree	Cycles	Neurons (Min./Max./Avg.)
10	0.03 → 0.36	12 → 106	0 → 119	0 → 12	0 → 18	0 → 4	120 (5/20/10) → 3640 (5/53/34)
32	0.12 → 1.43	12 → 82	0 → 120	0 → 8	0 → 27	0 → 3	384 (16/64/32) → 9728 (18/182/119)
64	0.30 → 2.14	12 → 43	0 → 103	0 → 8	0 → 25	0 → 8	768 (32/128/64) → 7808 (32/352/181)
84	0.43 → 1.86	12 → 21	0 → 119	0 → 11	0 → 17	0 → 6	1008 (42/168/84) → 3360 (64/256/160)
128	0.79 → 3.16	12 → 17	0 → 82	0 → 8	0 → 15	0 → 8	1536 (64/256/128) → 4864 (80/640/286)

Dim: 中間層の次元
Params(M): パラメータ数
Clusters: クラスターの数
Connections: エッジの数
Topological Depth: 不明
Max In-Degree: クラスターの最大次数
Cycles: 環状構造の数
Neurons: ニューロン数

結果

自律的に進化することでアーキテクチャを形成可能



Table 2: Research on the ablation of Neuron Clusters and their connections.

Raw					A: new NCs & all conns			B: new NCs & their conns			C: all conns		
Dim.	Clusters	Connections	Params	Top-1	Params	Top-1	Perf. Gap	Params	Top-1	Perf. Gap	Params	Top-1	Perf. Gap
10	106	119	0.36M	69.28	0.04M	32.28	-53.41	0.05M	35.4	-48.90	0.75M	32.71	-52.79
32	82	120	1.43M	73.12	0.21M	35.94	-50.85	1.31M	44.76	-38.79	0.23M	28.73	-60.71
64	43	103	2.14M	73.58	0.66M	30.63	-58.37	0.79M	52.94	-28.05	1.72M	27.33	-62.86
84	21	119	1.86M	74.00	0.63M	33.75	-54.39	1.07M	66.7	-9.86	1.02M	23.32	-68.49
128	17	82	3.16M	72.84	1.45M	34.70	-52.36	2.24M	69.43	-4.68	1.81M	29.08	-60.08

結果

複雑なトポロジカル構造が性能向上の鍵である

- 個々のラスタタに類似した限られた局所的な特徴を効果的に集約できる
- 人間の脳の生物学的構造と一致





図3. 入力層のニューロン重み行列の可視化

LuminaNet

- 古いクラスター
- 新しいクラスター



入力層のエンコーダー
重み行列を可視化

結果

古いクラスター

- 方向性及び形状の選好性を示す

新しいクラスター

- 特定の選好性を示さない



実験①：可視化（ニューロン層）

23/27




図4. NLの特徴量のMDS可視化




図5. NLの出力活性化（一部抜粋）

結果

Backwordの前後で活性化の大きさに
顕著な変化がみられる

- Forward: Pass1後(順方向情報のみ)
- Backward: Pass2後(フィードバック情報を含む)



考察

自律的に形成された接続が、強度の
異なる興奮性・抑制性信号を効果的
に伝達できる




図6. CIFAR10におけるLuminaNetが自律的に形成したアーキテクチャ

結果

中間層(少)：クラスターを生成するために分割に依存する
 中間層(多)：より深い階層構造や再帰的接続へと進化する



Table 4: Baseline comparison for the text generation task.

Model	Dim.	Pos.	Params (M)	Structure	Evolve (Params)	PPL	Top-1	Top-3	Top-5	FLOPs (T)	Mem. (G)
GPT-2 _{1H-12L}	384	✓	24.46	Transformer	-	4.08	64.39	81.82	87.08	4.13	23.13
GPT-2 _{12H-12L}	384	✓	24.46	Transformer	-	4.02	64.66	82.07	87.29	4.13	23.13
GPT-2 _{1H-1L}	384	✓	4.94	Transformer	-	9.73	50.53	67.54	74.11	2.26	9.53
GPT-2 _{12H-1L}	384	✓	4.94	Transformer	-	8.08	53.29	70.59	77.02	2.27	9.65
LuminaNet _{Conn}	384	-	43.24	BNN	82.47M → 43.24M	8.40	53.38	70.18	76.34	1.68	5.12
LuminaNet	384	-	44.37	BNN	15.76M → 44.37M	8.70	52.88	69.62	75.83	1.50	4.74
LuminaNet _{Conn}	256	-	29.12	BNN	36.13M → 29.12M	11.22	49.12	65.35	71.72	1.09	3.85
LuminaNet	256	-	15.55	BNN	6.31M → 15.55M	13.49	47.31	63.20	69.51	0.55	2.53

結果

- 帰納バイアスにより、生成品質はTransformerを大きく下回る
- ある程度の時系列依存性を捉えることができる



生物の脳の構造的・進化的メカニズムに整合する、
新しい人工ニューラルネットワークのパラダイムを提案

畳み込み層、アテンション機構などを一切含まない、
自己アーキテクチャ進化型ネットワークの『LuminaNet』を実装

アーキテクチャの進化、内部のデータフロー、情報の伝播の強さに
関して高い解釈性を有している

自律的に構築・最適化できることを実証
自己進化の鍵は複雑なトポロジカル構造にあることを示した