

Self-Supervised Learning from Images with a Joint-Embedding Predictive Architecture (JEPA)

2026年7月24日

小林遼翔



目次

- ①論文概要
- ②従来研究：自己教師あり学習の系統
- ③提案手法：I-JEPAの構造と損失
- ④実験(線形評価・少数ラベル・転移学習・局所タスクなど)
- ⑤まとめ



論文概要

人手で設計されたデータ拡張を使わずに、高い意味性を持つ画像表現を学習する手法

課題

- ・人が設計したデータ拡張に依存し、タスクに必要な情報まで失う可能性がある。
- ・画素の細かな復元に学習が向かい、意味的な表現を効率よく学びにくい。

解決

見えている領域から、隠れた領域の画素ではなく抽象的な意味表現を予測する。

結果


300epで81.1%、MAEより10倍効率化




従来研究：自己教師あり学習の系統

4


I-JEPAは「生成型」と「結合埋め込み型」の中間を狙っている



(a) Joint-Embedding Architecture



(b) Generative Architecture



(c) Joint-Embedding Predictive Architecture

a 不変性

同じ画像の複数
ビューを近い表現へ
寄せる。
SimCLR, DINO, iBOT
など

b 生成型

入力の一部を壊し、
画素またはトークン
として復元する。
MAE, BEiT など

c JEPA


入力空間ではなく、
埋め込み空間
で予測する。
I-JEPAは画像版
の具体化



従来研究：不変性ベース手法

5

複数ビューを近づけるが、手作業の拡張に依存する



課題

- ◆ 分類とセグメンテーションでは必要な不変性が異なる
- ◆ 画像向けの拡張を音声・テキストなどへ一般化しにくい
- ◆ 拡張設計が強い帰納バイアスとして働く

I-JEPAへの接続


- ◆ ビュー拡張に頼らず、同一画像内の文脈から予測する
- ◆ 「同じにする」より「予測できる表現」を学習する



従来研究：生成型・マスク再構成

6

欠損パッチを復元するが、意味表現が弱くなりやすい



弱点

- ◆ ピクセル復元は色・質感など弱い情報に引っ張られる
- ◆ 線形評価や少数ラベル転移では意味的表現が弱い
- ◆ 十分利用するには大規模な fine-tuning が必要になりやすい

I-JEPAの発想


- ◆ 復元する対象を「画素」から「意味表現」へ変える
- ◆ 不要なピクセル細部を捨て、下流タスクに有効な特徴を学ぶ



提案手法：I-JEPAの全体像

7

単一コンテキストから複数ターゲットの表現を予測



1 Context Encoder

可視パッチのみをViTで処理し、
文脈表現 s_x を得る

2 Predictor

位置マスクトークンを条件に、
ターゲット位置の表現を予測する

3 Target Encoder

ターゲットブロックの
正解表現 s_y を生成する。
重みはEMAで更新する



Context生成とMultiblock masking

8

大きいターゲットと広いコンテキストで学ばせる




Figure 4. Examples of our context and target-masking strategy.

target

- ◆ 4つのブロックをランダム抽出
- ◆ スケール：0.15～0.2
- ◆ Aspect比：0.75～1.5
- ◆ 比較的大きく、意味を含みやすい

context

- ◆ 単一ブロックを抽出
- ◆ スケール：0.85～1.0
- ◆ ターゲット重複部は除外
- ◆ 情報は豊富だが疎で効率的

なぜ重要か

- ◆ 小さすぎるパッチ予測では意味を学びにくい
- ◆ 空間的に分散した文脈が大域的推論を促す
- ◆ 「見えている周囲」から「隠れた意味」を当てる課題になる



予測器と損失関数

予測器

$$\hat{s}_y(i) = \{\hat{s}_{y_j}\}_{j \in B_i} = g_\phi(s_x, \{m_j\}_{j \in B_i})$$

コンテキスト表現 s_x と各ターゲット位置のマスクトークンを入力する。
マスクトークンは、共有学習ベクトルと位置埋め込みによって構成される。

損失

$$\frac{1}{M} \sum_{i=1}^M D(\hat{s}_y(i), s_y(i)) = \frac{1}{M} \sum_{i=1}^M \sum_{j \in B_i} \|\hat{s}_{y_j} - s_{y_j}\|_2^2$$



評価の狙い：I-JEPAが「拡張なし」「表現空間予測」「少ない計算」
でどこまで有効かを確認する

ImageNet-1Kによる線形評価

事前学習した表現が、
画像分類にそのまま
使いやすいか

表 1

ImageNet-1%

少ない教師ラベルでも
使いやすい表現か評価

表2

転移分類

別の画像データセット
にも応用できるか

表3

局所タスク

物体の数や距離など、画像内の
細かい情報を捉えられるか

表4

スケーリング

計算量・データ量・モデル規模
を増やした時の性能評価

表5・図5

アブレーション

I-JEPAのどの設計が
性能向上に重要か評価

表6・図6



実験①：ImageNet-1K線形評価

11

拡張なし手法の中で高い評価のもの

Method	Arch.	Epochs	Top-1
<i>Methods without view data augmentations</i>			
data2vec [8]	ViT-L/16	1600	77.3
	ViT-B/16	1600	68.0
MAE [36]	ViT-L/16	1600	76.0
	ViT-H/14	1600	77.2
CAE [22]	ViT-B/16	1600	70.4
	ViT-L/16	1600	78.1
I-JEPA	ViT-B/16	600	72.9
	ViT-L/16	600	77.5
	ViT-H/14	300	79.3
	ViT-H/16 ₄₄₈	300	81.1
<i>Methods using extra view data augmentations</i>			
SimCLR v2 [21]	RN152 (2×)	800	79.1
DINO [18]	ViT-B/8	300	80.1
iBOT [79]	ViT-L/16	250	81.0

Point

- ◆I-JEPA ViT-H/14：300epで79.3%
- ◆I-JEPA ViT-H/16_448：300epで81.1%
- ◆MAE ViT-H/14：1600epで77.2%
- ◆拡張なしでもiBOTに匹敵する性能

まとめ

- ◆同じ「ビューの拡張なし」でもピクセル復元より表現空間予測が強い
- ◆少ないエポックで高精度な表現を得られた



実験②：ImageNet-1%少数ラベル評価

12

少ない教師ラベルでも使いやすい表現か評価

Method	Arch.	Epochs	Top-1
<i>Methods without view data augmentations</i>			
data2vec [8]	ViT-L/16	1600	73.3
MAE [36]	ViT-L/16	1600	67.1
	ViT-H/14	1600	71.5
I-JEPA	ViT-L/16	600	69.4
	ViT-H/14	300	73.3
	ViT-H/16 ₄₄₈	300	77.3

<i>Methods using extra view data augmentations</i>			
iBOT [79]	ViT-B/16	400	69.7
DINO [18]	ViT-B/8	300	70.0
SimCLR v2 [35]	RN151 (2×)	800	70.2
BYOL [35]	RN200 (2×)	800	71.2
MSN [4]	ViT-B/4	300	75.7

Setting

- ◆利用可能なラベルはImageNetの1%のみ
- ◆1クラスあたり約12～13枚
- ◆Fine-tuningかlinear probingで適応

まとめ

- ◆I-JEPA ViT-H/14：73.3%でdata2vec ViT-L/16と同等
- ◆I-JEPA ViT-H/16_448：77.3%でMSN75.7%を上回る
- ◆解像度とモデル規模の拡大で性能が伸びることが分かった



実験③④：転移分類と局所予測タスク

13

意味的表現だけでなく局所特徴も評価

Method	Arch.	CIFAR100	Places205	iNat18
<i>Methods without view data augmentations</i>				
data2vec [8]	ViT-L/16	81.6	54.6	28.1
MAE [36]	ViT-H/14	77.3	55.0	32.9
I-JEPA	ViT-H/14	87.5	58.4	47.6
<i>Methods using extra view data augmentations</i>				
DINO [18]	ViT-B/8	84.9	57.9	55.9
iBOT [79]	ViT-L/16	88.3	60.4	57.3

Method	Arch.	Clevr/Count	Clevr/Dist
<i>Methods without view data augmentations</i>			
data2vec [8]	ViT-L/16	85.3	71.3
MAE [36]	ViT-H/14	90.5	72.4
I-JEPA	ViT-H/14	86.7	72.4
<i>Methods using extra data augmentations</i>			
DINO [18]	ViT-B/8	86.6	53.4
iBOT [79]	ViT-L/16	85.7	62.8

転移分類

- ◆ I-JEPAはMAE・data2vecを大幅に上回る
- ◆ CIFAR100で87.5, Places205で58.4
- ◆ DINOをCIFAR100とPlaces205で上回る

局所予測

- ◆ CLEVR/Count : 86.7でDINO/iBOTを上回る
- ◆ CLEVR/Dist : 72.4でMAEと同等、DINO/iBOTを大きく上回る
- ◆ ビュー不変性だけでは低水準タスクが弱くなりえる




実験⑤：スケラビリティと計算効率

14

1反復は少し遅いが、少ない反復で収束する

Pretrain	Arch.	CIFAR100	Place205	INat18	Clevr/Count	Clevr/Dist
IN1k	ViT-H/14	87.5	58.4	47.6	86.7	72.4
IN22k	ViT-H/14	89.5	57.8	50.5	88.6	75.0
IN22k	ViT-G/16	89.5	59.1	55.3	86.7	73.0



計算効率

- ◆ 表現空間ターゲット計算により
1反復は約7%遅い
- ◆ 一方で約5倍少ない反復で収束
- ◆ ViT-H/14でもiBOT ViT-S/16より
少ない計算量

データ・モデルサイズ


- ◆ IN1k→IN22kで多くの転移タスクが改善
- ◆ ViT-G/16はPlace205・iNat18で改善
- ◆ 大きいパッチは局所タスクには
不利な可能性がある



実験⑥：アブレーションと可視化

15

何が効いているのかを確認する



Mask	Targets		Context		Avg. Ratio*	Top-1
	Type	Freq.	Type			
multi-block	Block(0.15, 0.2)	4	Block(0.85, 1.0) × Complement		0.25	54.2
rasterized	Quadrant	3	Complement		0.25	15.5
block	Block(0.6)	1	Complement		0.4	20.2
random	Random(0.6)	1	Complement		0.4	17.6

*Avg. Ratio is the average number of patches in the context block relative to the total number of patches in the image.



まとめ

16

◆課題

不変性ベースは拡張依存、生成型はがぞ復元に寄りやすい

◆提案

ターゲットエンコーダが作る抽象表現を、コンテキストから予測する

◆結果

線形評価・少数ラベル・転移学習・局所タスクにおいてMAE/data2vecより強い傾向があった

◆結論

提案手法(I-JEPA)は「ピクセルを復元せずに、意味的表現を効率よく学習する」方向性を示した。